

Representaciones temporales para el análisis de variabilidad fisiológica en el ciclo menstrual mediante DTW y alineamiento al pico de LH

Dara Gama, Naxshelly García

Centro de Investigación en Matemáticas, Unidad Monterrey

Maestría en Cómputo Estadístico

Proyecto final de Ciencia de Datos

Resumen—Se presenta un análisis de series temporales fisiológicas multivariadas provenientes del conjunto de datos MCPhases, el cual contiene información hormonal, cardíaca, térmica y de actividad física de mujeres jóvenes monitoreadas durante aproximadamente 90 días. El trabajo consta de tres etapas principales: primero, la construcción de un conjunto de datos consolidado mediante un proceso de extracción, transformación y carga de seis fuentes de información; segundo, el análisis de similitud interindividual mediante Dynamic Time Warping multivariado bajo distintas estrategias de normalización y métodos de clustering jerárquico; y tercero, la exploración de una representación fisiológicamente informada basada en el alineamiento de las señales respecto al pico de hormona luteinizante.

Los resultados muestran que la estructura detectada por DTW depende fuertemente de la estrategia de normalización. La normalización por sujeto elimina gran parte de la variabilidad interindividual, mientras que la normalización global amplía el efecto de sujetos atípicos. Aunque algunas combinaciones producen valores moderados de silhouette score, no se encontró evidencia robusta de grupos fisiológicos discretos. Los participantes parecen distribuirse a lo largo de un continuo de perfiles fisiológicos más que en clusters claramente separados. Finalmente, se discute el alineamiento al pico de LH como una representación alternativa que incorpora conocimiento fisiológico previo y permite comparar perfiles alrededor de la ovulación.

Index Terms—Dynamic Time Warping, ciclo menstrual, wearables, clustering, series temporales multivariadas, pico de LH, MCPhases.

I. INTRODUCCIÓN

El uso de dispositivos portátiles o *wearables* ha permitido registrar de manera continua señales fisiológicas como frecuencia cardíaca, temperatura corporal, actividad física y calidad del sueño. En el contexto de la salud menstrual, estas señales resultan particularmente relevantes, ya que el ciclo menstrual está asociado con cambios hormonales y fisiológicos que pueden observarse indirectamente mediante sensores no invasivos.

Sin embargo, el análisis de datos fisiológicos longitudinales presenta varios retos. En primer lugar, las señales son multivariadas, ruidosas y presentan diferentes escalas. En segundo lugar, los eventos fisiológicos relevantes, como la ovulación, no ocurren en el mismo día calendario para todas las mujeres. Por ello, comparar directamente las trayectorias temporales puede ocultar patrones relevantes o generar estructuras artificiales.

En este trabajo se analiza el conjunto de datos MCPhases, el cual contiene mediciones hormonales y fisiológicas de mujeres adultas jóvenes durante aproximadamente 90 días. El objetivo principal es caracterizar la variabilidad fisiológica entre participantes mediante dos enfoques complementarios: el uso de Dynamic Time Warping sobre trayectorias completas y la construcción de representaciones alineadas al pico de LH, un evento hormonal asociado a la ovulación.

I-A. Preguntas de investigación

Las preguntas que guían este trabajo son:

1. ¿Existen perfiles fisiológicos diferenciados entre mujeres durante el ciclo menstrual?
2. ¿Cómo afecta la estrategia de normalización a la estructura de similitud obtenida mediante DTW?
3. ¿Una representación alineada al pico de LH permite capturar mejor la variabilidad fisiológica que el análisis de trayectorias completas?

I-B. Objetivos

El objetivo general del proyecto es caracterizar y comparar perfiles fisiológicos de mujeres durante el ciclo menstrual utilizando series temporales multivariadas, evaluando distintas representaciones temporales basadas en DTW y en alineamiento al pico de LH.

Los objetivos específicos son:

1. Construir un conjunto de datos fisiológico longitudinal consolidado integrando información hormonal, cardíaca, térmica y de actividad física.
2. Evaluar la estructura de similitud entre participantes mediante DTW multivariado sobre trayectorias fisiológicas completas, analizando el efecto de distintas estrategias de normalización y métodos de clustering.
3. Explorar una representación fisiológicamente informada basada en el alineamiento al pico de LH y comparar su capacidad para caracterizar la variabilidad entre mujeres respecto al enfoque basado en trayectorias completas.

II. DATOS

II-A. Conjunto de datos MCPhases

Se utilizó la base de datos MCPhases [1], disponible en PhysioNet. Esta base contiene información fisiológica, hormonal y auto-reportada de mujeres adultas jóvenes monitoreadas

durante aproximadamente tres meses. Las mediciones provienen de tres dispositivos principales: Fitbit Sense (frecuencia cardíaca continua, temperatura de muñeca y actividad), Mira Plus (concentración de metabolitos hormonales en orina: LH y estrógeno) y Dexcom G6 (glucosa intersticial continua). Adicionalmente, las participantes llevaron registros auto-reportados de fase del ciclo y síntomas.

En este proyecto se trabajó únicamente con el intervalo 2022 y se utilizaron las señales asociadas a actividad física, frecuencia cardíaca, temperatura de muñeca y hormonas. Las variables de glucosa no fueron incluidas debido a disponibilidad limitada para el intervalo seleccionado.

Cuadro I: Fuentes de información utilizadas.

Fuente	Información utilizada
Active minutes	Actividad física diaria
Resting heart rate	Frecuencia cardíaca en reposo
Heart rate	Frecuencia cardíaca intradiaria
Hormones and self-report	LH, estrógeno y fase del ciclo
Wrist temperature	Temperatura diferencial de muñeca
Computed temperature	Temperatura procesada

El dataset consolidado previo a limpieza contó con 3,698 filas $\times$ 10 columnas y 42 sujetos únicos, con una mediana de 90 días de observación por sujeto.

III. METODOLOGÍA

III-A. Construcción del conjunto de datos consolidado

El primer paso consistió en construir un conjunto de datos longitudinal con una fila por sujeto y día de estudio. Para ello se integraron las distintas fuentes mediante las variables *id* y *day_in_study*.

Para la actividad física se construyó la variable de porcentaje de movimiento diario:

$$\text{movement_pct} = 1 - \frac{\text{minutos sedentarios}}{\text{minutos totales}}. \quad (1)$$

La frecuencia cardíaca en reposo se tomó como una variable diaria. Para la frecuencia cardíaca intradiaria, registrada aproximadamente cada cinco segundos, se calcularon ocho métricas resumen por sujeto y día: media, desviación estándar, rango, coeficiente de variación, cambio absoluto promedio, desviación de los cambios, número de cambios de dirección y longitud del camino. Dado que estas métricas estaban correlacionadas entre sí, se aplicó análisis de componentes principales (PCA) y se conservaron los tres primeros componentes, los cuales explican en conjunto el **82.3 %** de la varianza acumulada (PC1: 51.4 %, PC2: 19.7 %, PC3: 11.2 %):

$$\text{HR} = (\text{hr_pc1}, \text{hr_pc2}, \text{hr_pc3}). \quad (2)$$

De manera análoga, para la temperatura de muñeca se calcularon nueve estadísticos diarios (media, SD, mín, máx, rango, delta medio, delta SD, longitud de camino, percentiles 10 y 90) y se aplicó PCA. Los tres primeros componentes explican el **78.6 %** de la varianza acumulada (PC1: 44.1 %, PC2: 22.3 %, PC3: 12.2 %):

$$\text{WTMP} = (\text{wtmp_pc1}, \text{wtmp_pc2}, \text{wtmp_pc3}). \quad (3)$$

Los seis bloques se integraron mediante *outer joins* sucesivos sobre (*id*, *day_in_study*), conservando todos los días registrados. El conjunto consolidado final contiene las variables mostradas en la Tabla II.

Cuadro II: Variables fisiológicas utilizadas en el análisis.

Variable	Descripción
movement_pct	Porcentaje de tiempo activo diario
rhr_value	Frecuencia cardíaca en reposo
hr_pc1-hr_pc3	Componentes de dinámica cardíaca
lh	Hormona luteinizante (mIU/mL)
estrogen	Estrógeno (pg/mL)
wtmp_pc1-wtmp_pc3	Componentes de temperatura de muñeca

III-B. Limpieza e imputación

Los valores de RHR iguales a cero fueron tratados como artefactos y reemplazados por valores faltantes. Posteriormente se aplicó interpolación lineal dentro de cada sujeto hacia ambas direcciones. Los sujetos con señales completamente ausentes fueron eliminados; de igual forma, se excluyeron los sujetos con menos de 90 días de datos para garantizar series comparables. El conjunto final para análisis DTW quedó compuesto por **39 sujetos y 10 señales fisiológicas**.

Cuadro III: Resumen de imputación por interpolación lineal.

Variable	Antes	Después	Imputados
rhr_value	782	0	782
hr_pc1-pc3	215	90	125
lh	223	0	223
estrogen	224	0	224
wtmp_pc1-pc3	508	0	508

III-C. Dynamic Time Warping multivariado

Para cada sujeto *i* se construyó una matriz temporal:

$$X_i \in \mathbb{R}^{90 \times 10}, \quad (4)$$

donde las filas representan días y las columnas señales fisiológicas. La distancia entre dos sujetos se calculó mediante DTW multivariado [2], que permite comparar series con desfases o deformaciones temporales al buscar la trayectoria de alineamiento óptima:

$$\text{DTW}(X, Y) = \min_{\pi} \sum_{(i,j) \in \pi} d(X_i, Y_j), \quad (5)$$

donde π es una trayectoria de alineamiento válida y $d(X_i, Y_j)$ es la distancia local entre observaciones multivariadas. Se calculó una matriz de distancias 39×39 , correspondiente a $\binom{39}{2} = 741$ pares únicos.

III-D. Estrategias de normalización

Se compararon tres estrategias de normalización previas al cálculo DTW:

1. **Raw:** señales originales sin transformación. Conserva diferencias de magnitud pero puede ser dominada por variables de mayor escala, como el estrógeno (0–500 pg/mL frente a LH 0–50 mIU/mL).
2. **Global z-score:** estandarización de cada señal usando la media y desviación estándar de toda la cohorte. Equipara escalas entre variables y conserva diferencias de magnitud entre sujetos.
3. **Subject z-score:** estandarización de cada señal dentro de cada sujeto. Elimina diferencias de nivel y amplitud individuales; enfatiza únicamente la forma temporal de las señales.

III-E. Clustering jerárquico

A partir de las matrices de distancia DTW se aplicó clustering jerárquico con dos métodos de enlace: *average* y *complete*. Para cada combinación se evaluó la calidad de los clusters mediante el silhouette score [3], seleccionando $k \in [2, 8]$.

Nota metodológica: el enlace de Ward fue descartado porque minimiza la varianza intracluster bajo métrica euclidiana y no está definido para matrices de distancias precomputadas no euclidianas, como las producidas por DTW.

Cuadro IV: Interpretación del silhouette score.

Score	Interpretación
> 0,70	Separación muy fuerte
0,50–0,70	Buena estructura
0,25–0,50	Estructura moderada
< 0,25	Estructura débil

III-F. Alineamiento al pico de LH

Como representación alternativa, las series temporales de cada sujeto se alinearon respecto al día de máximo valor de LH. Esta decisión incorpora conocimiento fisiológico previo: el pico de LH es el detonador de la ovulación, ocurriendo típicamente 24–36 horas antes de la liberación del óvulo. Para cada sujeto i se definió:

$$t_i^* = \arg \max_t LH_i(t), \quad (6)$$

y se construyó una ventana temporal de ± 20 días alrededor de dicho pico:

$$[t_i^* - 20, t_i^* + 20]. \quad (7)$$

El tensor resultante tiene dimensiones $N \times 41 \times 5$, donde N es el número de sujetos con ventana completa y las cinco señales son: lh, estrogen, rhr_value, wtmp_pc1 y movement_pct. Sobre estos perfiles alineados se aplicaron K-Means, K-Medoids (con distancia DTW precomputada) y HDBSCAN (sin k fijo, con reducción PCA previa).

III-G. DTW intra-sujeto y desfases temporales

Adicionalmente, se exploró la sincronización temporal entre pares de señales dentro de cada sujeto mediante DTW univariado. El desfase se estimó como la mediana de las diferencias $\text{lag} = j - i$ a lo largo de la trayectoria óptima, donde un valor negativo indica que la señal A tiende a preceder a la señal B.

IV. RESULTADOS

IV-A. Exploración inicial de señales fisiológicas

La Figura 1 muestra un ejemplo de señales fisiológicas multivariadas para un sujeto. Se observa que las variables presentan escalas, niveles de ruido y patrones temporales distintos, lo cual justifica el uso de técnicas específicas para series temporales multivariadas. El análisis exploratorio por fase del ciclo (Fig. 2) muestra que LH y estrógeno presentan las diferencias más marcadas entre fases, con alta variabilidad interindividual dentro de cada una.




Figura 1: Ejemplo de señales fisiológicas multivariadas para un sujeto.




Figura 2: Distribución de variables fisiológicas por fase del ciclo menstrual.

IV-B. Distribución de distancias DTW

Las tres estrategias de normalización produjeron distribuciones de distancia muy distintas (Tabla V). El resultado más importante es que la normalización por sujeto reduce el coeficiente de variación de las distancias al 4 %, frente al 42 % de los datos crudos. Esto indica que dicha normalización

elimina gran parte de la variabilidad interindividual que se buscaba analizar.

Cuadro V: Distribución de distancias DTW por estrategia de normalización ($n = 741$ pares).

Estrategia	Media	SD	CV	Rango
Raw	876.1	370.5	42 %	249–2997
Global z-score	38.8	9.6	25 %	23.2–74.9
Subject z-score	37.6	1.4	4 %	33.7–42.5

IV-C. Resultados del clustering jerárquico

La Tabla VI muestra los resultados de las seis combinaciones evaluadas. El mayor silhouette (0.438) lo obtiene la normalización global en ambos métodos de enlace; sin embargo, la partición resultante es degenerada: un grupo de 38 sujetos frente a uno solo. Esto refleja el aislamiento de un individuo atípico (sujeto 1), no la existencia de dos grupos fisiológicos robustos.

Con datos crudos y *average linkage* se obtiene una partición de 35 contra 4 sujetos con silhouette de 0.393. Este resultado puede reflejar la presencia de un pequeño grupo con valores extremos de estrógeno, aunque no necesariamente una diferencia fisiológica real. La normalización por sujeto produce valores cercanos a cero ($\approx 0,026$), confirmando que esta transformación anula la información interindividual.

Cuadro VI: Comparación de estrategias de normalización y linkage (DTW jerárquico).

Modo	Linkage	k^*	Silhouette	Tamaños
Global z-score	Average	2	0.438	38, 1
Global z-score	Complete	2	0.438	38, 1
Raw	Average	2	0.393	35, 4
Raw	Complete	2	0.256	23, 16
Subject z-score	Complete	2	0.027	24, 15
Subject z-score	Average	2	0.026	14, 25

Los resultados de los métodos aplicados sobre los perfiles alineados al pico de LH se resumen en la Tabla VII. Los silhouette scores son bajos en todos los casos ($< 0,04$), lo cual es consistente con la hipótesis de que los sujetos se distribuyen en un continuo fisiológico más que en grupos discretos.

Cuadro VII: Resultados de clustering sobre perfiles alineados al pico de LH.

Método	k	Silhouette	Inercia	Distribución
K-Means	2	0.0354	2316.1	{C0: 10, C1: 15}
	3	0.0113	1429.6	{C0: 7, C1: 9, C2: 9}
	4	0.0334	1185.9	{C0: 3, C1: 10, C2: 7, C3: 5}
K-Medoids	2	0.0208	—	{C0: 13, C1: 12}
	3	0.0142	—	{C0: 7, C1: 9, C2: 9}
	4	0.0129	—	{C0: 6, C1: 7, C2: 7, C3: 5}
HDBSCAN	—	—	—	{ruido: 25 (100 %)}

IV-D. Visualización de la estructura de clusters

Las Figuras 3 y 4 muestran los dendrogramas bajo datos crudos y global z-score respectivamente. En ambos casos no

se observan grupos claramente separados, sino estructuras dominadas por outliers o divisiones débiles. Para complementar la inspección jerárquica, se generaron proyecciones bidimensionales de la matriz de distancias DTW mediante UMAP [5] (con `metric="precomputed"`) y t-SNE (Fig. 5). En ambas proyecciones los sujetos se distribuyen de forma difusa, sin agrupaciones compactas, lo que confirma que la estructura de distancias es más cercana a un gradiente continuo que a clusters discretos.




Figura 3: Dendrograma: datos crudos, average linkage.




Figura 4: Dendrograma: global z-score, average linkage.




Figura 5: Proyecciones 2D de la matriz de distancias DTW. Los colores indican la asignación de cluster jerárquico (global z-score, average linkage). La distribución difusa confirma la ausencia de estructura discreta entre sujetos.

IV-E. Desfases temporales intra-sujeto

Las medianas del desfase temporal para pares de señales clave se muestran en la Tabla VIII. Los valores son cercanos a cero y presentan alta variabilidad entre sujetos, lo que indica que DTW encuentra alineamientos locales pero no existe un desfase consistente a nivel de cohorte.

Cuadro VIII: Mediana del desfase temporal en días por par de señales.

Par de señales	Mediana
LH → RHR	-1
LH → Estrógeno	0
Estrógeno → RHR	-3
LH → HR_PC1	0
Estrógeno → WTMP_PC1	+2

IV-F. Alineamiento al pico de LH

La Figura 8 muestra las señales fisiológicas alineadas al pico de LH. Esta representación hace comparables a las participantes en un eje temporal fisiológico, centrado en la ovulación. Las curvas promedio muestran cierta co-variación alrededor del pico; la variabilidad interindividual sigue siendo considerable, lo que sugiere que el alineamiento hormonal mejora la interpretabilidad pero requiere análisis adicionales para determinar su ventaja sobre el tiempo calendario.

Sobre los perfiles alineados se aplicaron K-Means, K-Medoids (con distancia DTW precomputada sobre el tensor $N \times 41 \times 5$) y HDBSCAN (sobre los primeros 10 componentes PCA del tensor vectorizado, que explican aproximadamente el 80 % de la varianza). Para K-Means se evaluaron valores de $k \in [2, 8]$ mediante la curva de codo (inercia intracluster), mostrada en la Figura 6. El mayor silhouette de K-Means se obtiene con $k = 2$ (silhouette = 0,035), aunque el valor sigue siendo bajo, lo que sugiere ausencia de separación nítida entre grupos.




Figura 6: Curva de codo (inercia vs. k) para K-Means sobre perfiles alineados al pico de LH.

K-Medoids con $k = 3$ produce grupos de tamaño $\{7, 9, 9\}$, más balanceados que los de K-Means. Los medoides son observaciones reales del dataset, lo que permite interpretar directamente los perfiles de cada grupo. HDBSCAN clasificó el 100 % de los sujetos como ruido (etiqueta -1), lo que indica que no existen regiones de densidad suficientemente alta en el espacio PCA para formar clusters compactos. Este resultado es el más informativo de los tres: la distribución de sujetos es intrínsecamente difusa incluso tras la alineación.

La Figura 7 muestra la distribución de sujetos por cluster en los tres métodos. Un hallazgo destacado en la inspección

de las trayectorias agrupadas es que el comportamiento de la RHR difiere entre clusters principalmente *después* de la ovulación: algunos grupos exhiben una caída sostenida en la fase lútea temprana, mientras que otros muestran un rebote o estabilización. Esto es consistente con la literatura sobre el efecto de la progesterona en la frecuencia cardíaca en reposo post-ovulatoria.



Figura 7: Distribución de sujetos por cluster en los tres métodos aplicados sobre perfiles alineados al pico de LH. HDBSCAN clasifica el 100 % de los sujetos como ruido (etiqueta -1), confirmando la ausencia de clusters densos.

K-Medoids con $k = 3$ identifica sujetos representativos cuyas trayectorias son directamente interpretables. Los medoides y las trayectorias individuales de LH por cluster se muestran en las Figuras 10 y 11.




Figura 8: Señales fisiológicas alineadas al pico de LH (± 20 días).

La Figura 9 muestra las trayectorias de LH agrupadas por K-Means ($k = 3$), junto con el centroide de cada grupo. La Figura 10 presenta los perfiles correspondientes a K-Medoids, donde cada panel muestra las trayectorias de todos los miembros del cluster junto al medoide (sujeto representativo real). Finalmente, la Figura ?? reporta la asignación de HDBSCAN sobre la proyección PCA, distinguiendo sujetos ruidosos (etiqueta -1) de los miembros de cada cluster denso.




Figura 9: K-Means ($k = 3$): centroides DBA por cluster sobre la ventana $[-20, +20]$ días.




Figura 10: K-Medoids ($k = 3$, DTW precomputado): trayectorias del sujeto medoide de cada cluster. Los medoides son observaciones reales del dataset.




Figura 11: Trayectorias individuales de LH por cluster (K-Medoids). La línea vertical indica $\tau = 0$ (pico de LH). El medoide se destaca en trazo grueso.

V. DISCUSIÓN

V-A. Por qué el clustering sin alineación no produce estructura robusta

La heterogeneidad en la duración del ciclo menstrual (típicamente 21–35 días) implica que el día calendario no es una referencia temporal compartida. Incluso con DTW, el sujeto A en día 20 puede estar en fase lútea mientras el sujeto B está en folicular, degradando la comparabilidad. Adicionalmente, el estrógeno (0–500 pg/mL) domina la distancia DTW en datos crudos. Con normalización global se reduce este efecto, pero persiste la desalineación. Con normalización por sujeto, la forma queda centrada pero la varianza interindividual de magnitud —que contiene información real— se pierde. Los resultados en los tres esquemas son consistentes con esta interpretación: no emergen agrupaciones biológicamente plausibles.

V-B. El valor del alineamiento fisiológico

Al anclar las series al pico de LH, las fases biológicamente equivalentes quedan superpuestas. El efecto es análogo a la alineación por evento en el análisis de potenciales evocados en neurociencia. Sin embargo, los bajos valores de silhouette obtenidos (máx. 0.035 en K-Means, $k = 2$) y el resultado de HDBSCAN —que clasificó el 100 % de los sujetos como ruido— indican que incluso bajo este marco de referencia fisiológico, los perfiles de las participantes no forman grupos discretos y compactos.

Un hallazgo interpretable emerge de la inspección visual de las trayectorias agrupadas: el **comportamiento de la RHR difiere entre clusters principalmente después de la ovulación**. Algunos grupos presentan una caída en la RHR durante la fase lútea temprana ($\tau > 0$), mientras que otros muestran estabilización o rebote. Esta diferencia en la respuesta post-ovulatoria es consistente con el efecto vasodilatador de la progesterona, cuya producción se inicia tras la ruptura folicular.

K-Medoids es especialmente adecuado en este contexto porque: (a) la distancia DTW es no euclidiana, (b) los medoids son observaciones reales del dataset, haciendo los centros de cluster directamente interpretables, y (c) es robusto a outliers en comparación con K-Means.

V-C. Limitaciones

1. **Tamaño muestral:** 39 sujetos (o menos con ventana completa) es insuficiente para conclusiones estadísticas sólidas. Los clusters deben considerarse exploratorios.
2. **Un único pico de LH por sujeto:** si un sujeto tiene múltiples ciclos en la ventana de estudio, solo se usa un pico.
3. **Calidad del etiquetado:** la fase del ciclo es auto-reportada, lo que introduce error de clasificación.
4. **Variables dominantes:** el estrógeno puede dominar las distancias si no se controla adecuadamente su escala relativa.

VI. USO DE INTELIGENCIA ARTIFICIAL

En este proyecto se utilizaron herramientas de IA generativa como apoyo en distintas etapas del desarrollo, siguiendo un esquema de co-pilotaje en el que las decisiones metodológicas y la validación de resultados permanecieron a cargo del equipo.

VI-A. Proceso ETL

Se construyó una primera versión del pipeline de forma manual, utilizando prompts *in-line* dentro de las celdas del notebook como guía para tareas puntuales. Algunos ejemplos de instrucciones empleadas:

- # max and min frequency of records per subject
- # counts by id
- # plot de las señales de un sujeto

Varios de estos comentarios se conservan en el notebook como documentación del proceso. Posteriormente se solicitó a la IA revisión de la estructura general del pipeline y mejora de la etapa final de consolidación del CSV, incluyendo la lógica de *outer joins* y la imputación por interpolación lineal.

VI-B. Verificación de estandarización y clustering jerárquico

Se generó con ayuda de IA un script auxiliar para explorar sistemáticamente las distintas combinaciones de tipo de estandarización (*raw*, global z-score, subject z-score) y métodos de enlace (*average*, *complete*), agilizando la comparación de los seis escenarios evaluados.

VI-C. Análisis DTW y clustering sobre perfiles alineados

Para el módulo de DTW, se informó a la IA de la estructura del *output* del ETL y de los objetivos del análisis. A partir de ello se generó una primera versión del script, la cual fue revisada por el equipo antes de su ejecución. Las decisiones sobre la ventana de alineamiento (± 20 días), la selección de señales y la interpretación de los resultados fueron tomadas de forma independiente.

VI-D. Observaciones generales

El uso de IA aceleró tareas de escritura de código repetitivo y exploración de parámetros, pero requirió supervisión activa. Un ejemplo concreto: la IA sugirió Ward linkage como método de clustering, el cual fue descartado por el equipo al identificar que no es válido para matrices de distancias precomputadas no euclidianas como las producidas por DTW.

VII. CONCLUSIONES

Este trabajo muestra que el clustering directo de series temporales fisiológicas del ciclo menstrual mediante DTW multivariado no produce agrupaciones robustas cuando las series no están alineadas temporalmente. La heterogeneidad de la duración del ciclo y las diferencias de escala entre señales impiden que la distancia DTW capture similitud biológica real. Los participantes se distribuyen en un continuo de perfiles fisiológicos más que en clusters discretos.

La alineación por el pico de LH proporciona un marco de referencia fisiológicamente coherente que hace comparables las trayectorias hormonales y autonómicas entre sujetos. Sin embargo, los silhouette scores obtenidos ($< 0,04$ en todos los métodos) y el resultado de HDBSCAN —que clasificó el 100 % de los sujetos como ruido— confirman que la variabilidad interindividual es continua, no discreta. El hallazgo más interpretable es que el comportamiento de la RHR difiere entre grupos *después* de la ovulación, lo que constituye una pista fisiológica para investigación futura.

VIII. TRABAJO FUTURO

Se propone profundizar en el análisis basado en alineamiento al pico de LH y extender el trabajo en las siguientes direcciones:

1. Comparar sistemáticamente la estructura de clustering obtenida sobre perfiles alineados vs. trayectorias completas mediante métricas de estabilidad bootstrap.
2. Analizar el subconjunto de sujetos del intervalo 2024. Este grupo, al haber participado en el estudio durante más tiempo, posiblemente estuvo en convivencia prolongada con otras participantes. Evidencia anecdótica sugiere sincronización menstrual entre cohabitantes, lo que podría producir mayor coherencia interindividual y facilitar la detección de clusters estables.
3. Evaluar modelos de pronóstico de series de tiempo (ARIMA, Prophet, redes LSTM) sobre las señales alineadas para predecir el timing del pico de LH.
4. Analizar con mayor detalle los sujetos atípicos identificados, especialmente el sujeto 1, para determinar si su atipicidad tiene base fisiológica o corresponde a un artefacto de medición.

REFERENCIAS

- [1] B. Lin et al., “mcPHASES: A Dataset of Physiological, Hormonal, and Self-reported Events and Symptoms for Menstrual Health Tracking with Wearables,” *PhysioNet*, version 1.0.0, 2025. doi: 10.13026/2x6a-2c81.
- [2] H. Sakoe and S. Chiba, “Dynamic programming algorithm optimization for spoken word recognition,” *IEEE Transactions on Acoustics, Speech, and Signal Processing*, vol. 26, no. 1, pp. 43–49, 1978.
- [3] P. J. Rousseeuw, “Silhouettes: A graphical aid to the interpretation and validation of cluster analysis,” *Journal of Computational and Applied Mathematics*, vol. 20, pp. 53–65, 1987.
- [4] R. J. G. B. Campello, D. Moulavi, and J. Sander, “Density-based clustering based on hierarchical density estimates,” *Pacific-Asia Conference on Knowledge Discovery and Data Mining*, pp. 160–172, 2013.
- [5] L. McInnes, J. Healy, and J. Melville, “UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction,” *arXiv preprint arXiv:1802.03426*, 2018.
- [6] L. Kaufman and P. J. Rousseeuw, “Partitioning around medoids (program PAM),” in *Finding Groups in Data: An Introduction to Cluster Analysis*, pp. 68–125, 1990.